Formalisation mathématique et instances

1 Notation

- E : ensemble des étudiants ;
- $t \in \{\text{LV2}, \text{LV1}, \text{TP}, \text{TD}\}$: type de groupes, $G(t)$: groupes de type t, $C(g)$: capacité du groupe g ;
- $s(e)$: LV2 choisie par l'étudiant e ; $P(g)$: parent hiérarchique de g (TP $\to$ TD $\to$ PROMO) ;
- $N(t)$: effectif à répartir de type t ; $k(t)$: nombre de groupes de type t que l'établissement ouvre (donnée fixée avant l'optimisation, contrainte dure).

2 Variables

$$x(e,g) \in \{0,1\} : \text{affectation de } e \text{ au groupe } g, \qquad y(g) \in \{0,1\} : \text{groupe } g \text{ ouvert},$$
$$n(g) = \sum_{e \in E} x(e,g) : \text{effectif de } g.$$

3 Contraintes dures

(C1)	$\forall e \in E,\ \forall t : \sum_{g \in G(t)} x(e,g) = 1$	un seul groupe par type,
(C2)	$\forall g : n(g) \le C(g)$	effectif maximal,
(C3)	$x(e,g) = 0$ si g incompatible avec $s(e)$	respect de $s(e)$ (césure, redoublant),
(C4)	$\forall e,\ \forall g \in G(\text{TP}) : x(e,g) \le x(e,P(g))$	cohérence hiérarchique.

(C5)	$\forall t : \sum_{g \in G(t)} y(g) = k(t)$	exactement $k(t)$ groupes ouverts,
(C6)	$\forall g : n(g) \le C(g)\, y(g)$	aucune place dans un groupe fermé,
(C7)	$\forall g : y(g) \le n(g)$	un groupe ouvert accueille au moins un étudiant.

L'ordre des décisions est structurel : C5 fixe la structure (combien de groupes), C1 à C3 et C7 placent les étudiants, f_1 n'optimise qu'à l'intérieur de cette structure. La faisabilité (dur) prime sur la qualité (souple).

4 Contraintes souples

Seul le critère de qualité reste souple, une fois la structure fixée par C5 :

$f_1 = \sum_t \sum_{g \in G(t)} \dfrac{\left\lvert n(g) - \frac{N(t)}{k(t)} \right\rvert}{\frac{N(t)}{k(t)}}$	équilibre relatif,
$f_4 =$ robustesse au changement	semaine 6 (hors statique).

La déviation est *relative* (divisée par la cible $N(t)/k(t)$) : un étudiant de trop pèse 20 % sur un TP de 5 mais 3 % sur un TD de 36, les types deviennent comparables. Correspondance avec la version initiale : l'ancien f_2 (nombre de groupes ouverts) est devenu la contrainte dure C5 ; l'ancien f_3 (parallélisation) n'est plus un critère, la schedulabilité est portée par le choix de $k(t)$ en donnée d'entrée.

5 Fonction objectif unique

$$\min_{x,y} \sum_c w(c)\, f(c), \qquad f(c) \in [0,1], \quad w(c) \geq 0, \quad \sum_c w(c) = 1, \tag{1}$$

les $f(c)$ étant normalisées dans $[0,1]$. Pour f_1, les bornes sont calculables : pire cas $f_1^{\max} = 2N(t)(k(t)-1)$ (tous les étudiants dans un seul groupe), meilleur cas atteignable $f_1^{\min} = 2r(k(t)-r)$ avec $r = N(t) \bmod k(t)$ (l'indivisibilité des étudiants empêche zéro), d'où

$$\tilde{f}_1 = \frac{f_1 - f_1^{\min}}{f_1^{\max} - f_1^{\min}} \in [0,1].$$

Exemples : $N = 12$, $k = 3$: $f_1^{\max} = 48$, la répartition 12/0/0 coûte 48 et 4/4/4 coûte 0 ; $N = 10$, $k = 3$: $f_1^{\min} = 4$, réalisée par 4/3/3. La normalisation est nécessaire car les critères n'ont pas les mêmes unités (écarts d'étudiants, nombres de groupes) : sans elle, f_1 écraserait les autres dans la somme pondérée et les poids $w(c)$ perdraient leur sens de taux d'échange. Implémentation CP-SAT : on minimise $\sum_g |k(t)\, n(g) - N(t)|$, forme entière équivalente (même minimiseur, sans flottants).

6 Justification de l'agrégation

Les poids w sont paramétrés, non fixés arbitrairement : utilisés uniformes aux semaines 4-5, ils seront appris aux semaines 6-8 par *inverse optimization* (« apprentissage par imitation » de l'affectation manuelle). L'agrégation est donc justifiée par la mesure, pas par déclaration.

7 Générateur d'instances synthétiques

Paramètres.

- effectif $n \in [50, 100]$ (bornes du cadrage, vérifiées par assertion) et graine ;
- distribution de LV2 (défaut : Allemand 45 %, Espagnol 20 %, Autre 35 %) ;
- capacités calées sur les données réelles : LV1 : 21, TP : 16, TD : 36 ;
- part de choix de LV2 pris le jour de la rentrée : 15 % ;
- cas particuliers : césure, 4 redoublants ;
- jeu étendu : effectifs tirés selon une loi normale $\mathcal{N}(64, 10)$ tronquée aux bornes $[50, 100]$ (taille moyenne de promo), parts de LV2 bruitées gaussiennement puis renormalisées (graines fixées, reproductible).

Sortie. Liste d'étudiants (id, LV2, choix tardif, statut) et proposition de groupes (nom, type, capacité, parent pour les TP), soit l'entrée directe du modèle CP-SAT.

8 Tests du générateur (seed 42)

Effectif n	Répartition LV2 (All. / Esp. / Autre)	Groupes LV2 / LV1 / TP / TD	Choix tardifs
50	23 / 8 / 19	5 / 3 / 4 / 2	8
75	35 / 13 / 27	5 / 4 / 5 / 3	10
80 (référence)	39 / 13 / 28	5 / 4 / 5 / 3	10
100	50 / 15 / 35	5 / 5 / 7 / 3	14

Les cas particuliers sont ajoutés à partir de $n \geq 60$ (instance $n = 50$: aucun). Le générateur est documenté et prêt à être remis avec les scripts commentés.